Rook&Ceph

部署Rook

Rook介绍

Rook是一个自管理的分布式存储编排系统，可以为Kubernetes提供便利的存储解决方案。Rook本身并不提供存储，而是在kubernetes和存储系统之间提供适配层，简化存储系统的部署与维护工作。目前，rook支持的存储系统包括：Ceph、CockroachDB、Cassandra、EdgeFS、Minio、NFS，其中Ceph为Stable状态，其余均为Alpha。本文仅介绍Ceph相关内容。Rook支持CSI，CSI可以做一些PVC快照、PVC扩容等操作。

Rook由Operator和Cluster两部分组成：

Operator：由一些CRD和一个All in one镜像构成，包含包含启动和监控存储系统的所有功能。主要用于有状态的服务，或者用于比较复杂应用的管理。
Cluster：负责创建CRD对象，指定相关参数，包括ceph镜像、元数据持久化位置、磁盘位置、dashboard等等...

Rook:

Agent: 在每个存储节点上运行，用于配置一个FlexVolume插件，和k8s的存储卷进行集成。挂载网络存储、加载存储卷、格式化文件系统。

Discover: 用于检测连接到存储节点上的设备。

Ceph:

OSD: 直接连接每个集群节点的物理磁盘或者是目录。集群的副本数，高可用性和容错性。

Mon: 集群监控，所有集群的节点都会向Mon汇报，他记录了集群的拓扑以及数据存储位置的信息。

MDS: 元数据服务器，负责跟踪文件层次结构并存储Ceph元数据。

RGW: restful API 接口

MGR: 提供额外的监控和界面。

一、实验环境最低配置

- 做这个实验需要高配置，每个节点配置不能低于**2核4G**
- k8s 1.19以上版本，快照功能需要单独安装snapshot控制器
- rook的版本大于1.3，不要使用目录创建集群，要使用单独的裸盘进行创建，也就是创建一个新的磁盘，挂载到宿主机，不进行格式化，直接使用即可。对于的磁盘节点配置如下

```
[root@k8s-master01 ~]# fdisk -l

Disk /dev/sda: 42.9 GB, 42949672960 bytes, 83886080 sectors
Units = sectors of 1 * 512 = 512 bytes
Sector size (logical/physical): 512 bytes / 512 bytes
I/O size (minimum/optimal): 512 bytes / 512 bytes
Disk label type: dos
```

```
Disk identifier: 0x000d76eb

   Device Boot      Start         End      Blocks   Id  System
/dev/sda1   *        2048     2099199     1048576   83  Linux
/dev/sda2         2099200    83886079    40893440   8e  Linux LVM

Disk /dev/sdb: 10.7 GB, 10737418240 bytes, 20971520 sectors  # 新的磁盘
Units = sectors of 1 * 512 = 512 bytes
Sector size (logical/physical): 512 bytes / 512 bytes
I/O size (minimum/optimal): 512 bytes / 512 bytes
```

二、部署Rook

2.1、Rook官方文档

```
https://rook.io/docs/rook/v1.5/ceph-quickstart.html
```

2.2、下载Rook安装文件

```
[root@k8s-master01 app]# git clone --single-branch --branch v1.5.3
https://github.com/rook/rook.git
```

2.3、配置更改

```
[root@k8s-master01 app]# cd rook/cluster/examples/kubernetes/ceph
# 修改Rook CSI镜像地址，原本的地址可能是gcr的镜像，但是gcr的镜像无法被国内访问，所以需要同步gcr的镜像到阿里云镜像仓库，文档版本已经为大家完成同步，可以直接修改如下：
[root@k8s-master01 ceph]# vim operator.yaml

##  47-52行更改为：
ROOK_CSI_CEPH_IMAGE: "quay.io/cephcsi/cephcsi:v3.1.2"
ROOK_CSI_REGISTRAR_IMAGE: "registry.cn-beijing.aliyuncs.com/dotbalo/csi-node-driver-registrar:v2.0.1"
ROOK_CSI_RESIZER_IMAGE: "registry.cn-beijing.aliyuncs.com/dotbalo/csi-resizer:v1.0.0"
ROOK_CSI_PROVISIONER_IMAGE: "registry.cn-beijing.aliyuncs.com/dotbalo/csi-provisioner:v2.0.0"
ROOK_CSI_SNAPSHOTTER_IMAGE: "registry.cn-beijing.aliyuncs.com/dotbalo/csi-snapshotter:v3.0.0"
ROOK_CSI_ATTACHER_IMAGE: "registry.cn-beijing.aliyuncs.com/dotbalo/csi-attacher:v3.0.0"
##

# 如果是其他版本，需要自行同步，同步方法可以在网上找到相关文章。
# 还是operator文件，新版本rook默认关闭了自动发现容器的部署，可以找到ROOK_ENABLE_DISCOVERY_DAEMON改成true即可：
# ROOK_ENABLE_DISCOVERY_DAEMON改成true即可：
- name: ROOK_ENABLE_DISCOVERY_DAEMON
          value: "true"
```

2.4、部署rook

```
# 1、进到/rook/cluster/examples/kubernetes/ceph目录
[root@k8s-master01 ceph]# pwd
/app/rook/cluster/examples/kubernetes/ceph

# 2、部署
[root@k8s-master01 ceph]# kubectl create -f crds.yaml -f common.yaml -f operator.yaml

# 3、等待operator容器和discover容器启动（全部变成1/1  Running 才可以创建Ceph集群）
[root@k8s-master01 ceph]# kubectl get pod  -n rook-ceph -owide
NAME                                  READY   STATUS    RESTARTS   AGE     IP
    NODE           NOMINATED NODE   READINESS GATES
rook-ceph-operator-7d569f655-6bcjv    1/1     Running   0          6m37s   10.244.195.13
   k8s-master03
rook-discover-bdk7k                   1/1     Running   0          4m2s    10.244.32.148
   k8s-master01
rook-discover-j6w4m                   1/1     Running   0          4m2s    10.244.58.247
   k8s-node02
rook-discover-pnp52                   1/1     Running   0          4m2s
 10.244.122.136   k8s-master02
rook-discover-spw8l                   1/1     Running   0          4m2s    10.244.195.21
   k8s-master03
rook-discover-vcqh2                   1/1     Running   0          4m2s    10.244.85.248
   k8s-node01
```

三、创建ceph集群

3.1、配置更改

主要更改的是osd节点所在的位置

```
[root@k8s-master01 ceph]# vim cluster.yaml
# 1、更改storage（自己指定使用磁盘的节点）
###
原配置：
  storage: # cluster level storage configuration and selection
    useAllNodes: true
    useAllDevices: true
更改为：
  storage: # cluster level storage configuration and selection
    useAllNodes: false
    useAllDevices: false
###
     - name: "k8s-master03"
       devices:
       - name: "sdb"
     - name: "k8s-node01"
```

```
        devices:
        - name: "sdb"
      - name: "k8s-node02"
        devices:
        - name: "sdb"
###
```

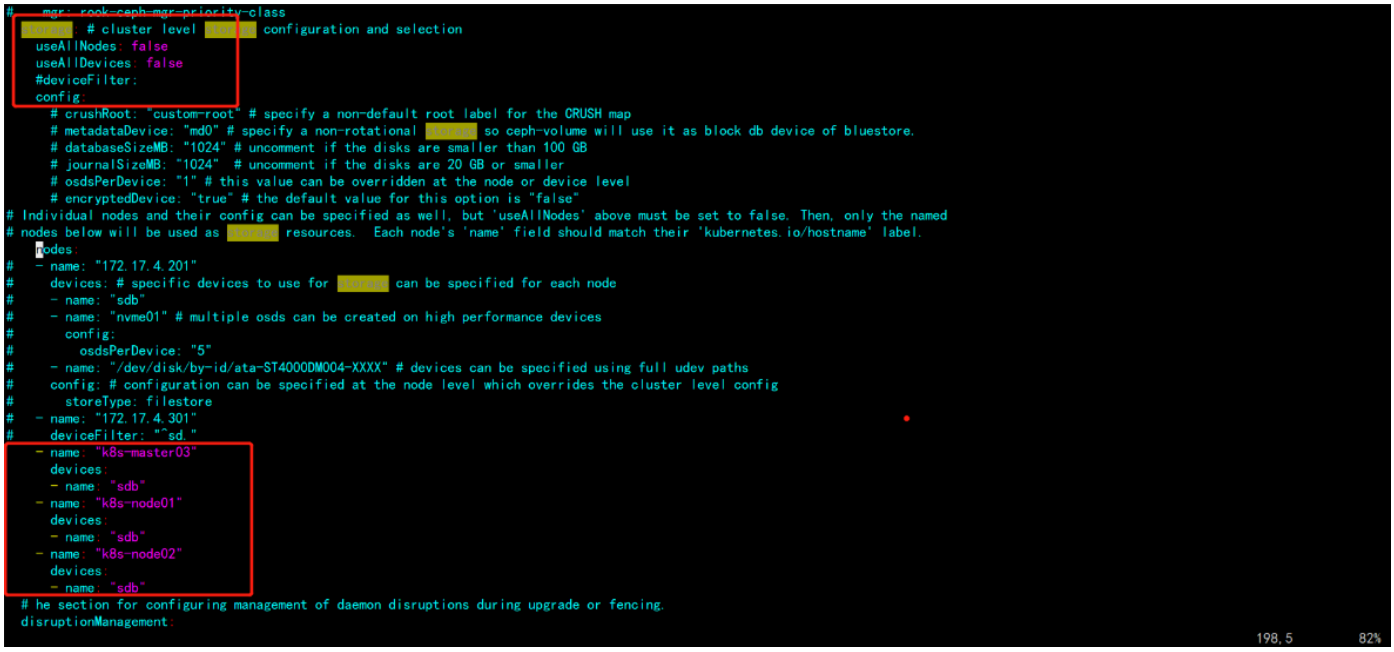

注意：新版必须采用裸盘，即未格式化的磁盘。其中k8s-master03 k8s-node01 node02有新加的一个磁盘，可以通过lsblk -f查看新添加的磁盘名称。建议最少三个节点，否则后面的试验可能会出现问题

3.2、创建Ceph集群

```
[root@k8s-master01 ceph]# kubectl create -f cluster.yaml
cephcluster.ceph.rook.io/rook-ceph created

# 创建完成后，可以查看pod的状态
[root@k8s-master01 ceph]# kubectl -n rook-ceph get pod
NAME                                                     READY   STATUS      RESTARTS
AGE
csi-cephfsplugin-2gp6j                                   3/3     Running     0
31m
csi-cephfsplugin-5bqp2                                   3/3     Running     0
17m
csi-cephfsplugin-df5xq                                   3/3     Running     0
31m
csi-cephfsplugin-gk8f8                                   3/3     Running     0
31m
csi-cephfsplugin-provisioner-785798bc8f-fcdng            6/6     Running     0
31m
csi-cephfsplugin-provisioner-785798bc8f-mkjpt            6/6     Running     4
31m
```

```
csi-cephfsplugin-xdw2t                                    3/3     Running     0
31m
csi-rbdplugin-8cs79                                       3/3     Running     0
31m
csi-rbdplugin-d4mrr                                       3/3     Running     0
31m
csi-rbdplugin-jg77k                                       3/3     Running     0
31m
csi-rbdplugin-ksq66                                       3/3     Running     0
21m
csi-rbdplugin-provisioner-75cdf8cd6d-gvwmn                6/6     Running     0
31m
csi-rbdplugin-provisioner-75cdf8cd6d-nqwrn                6/6     Running     5
31m
csi-rbdplugin-wqxbm                                       3/3     Running     0
31m
rook-ceph-crashcollector-k8s-master03-6f7c7b5fbc-rv4tc    1/1     Running     0
31m
rook-ceph-crashcollector-k8s-node01-6769bf677f-bsr7c      1/1     Running     0
31m
rook-ceph-crashcollector-k8s-node02-7c97d7b8d4-6xgkb      1/1     Running     0
31m
rook-ceph-mgr-a-75fc775496-cqjmh                          1/1     Running     1
32m
rook-ceph-mon-a-67cbdcd6d6-hpttq                          1/1     Running     0
33m
rook-ceph-operator-7d569f655-6bcjv                        1/1     Running     0
69m
rook-ceph-osd-0-9c67b5cb4-729r6                           1/1     Running     0
31m
rook-ceph-osd-1-56cd8467fc-bbwcc                          1/1     Running     0
31m
rook-ceph-osd-2-74f5c9f8d8-fwlw7                          1/1     Running     0
31m
rook-ceph-osd-prepare-k8s-master03-kzgbd                  0/1     Completed   0
94s
rook-ceph-osd-prepare-k8s-node01-hzcdw                    0/1     Completed   0
92s
rook-ceph-osd-prepare-k8s-node02-pxfcc                    0/1     Completed   0
90s
rook-discover-bdk7k                                       1/1     Running     0
67m
rook-discover-j6w4m                                       1/1     Running     0
67m
rook-discover-pnp52                                       1/1     Running     0
67m
rook-discover-spw8l                                       1/1     Running     0
67m
```

```
rook-discover-vcqh2                                    1/1     Running     0
67m
```

3.3、安装ceph snapshot控制器

k8s 1.19版本以上需要单独安装snapshot控制器，才能完成pvc的快照功能，所以在此提前安装下，如果是1.19以下版本，不需要单独安装。

```
# 1、snapshot控制器的部署在集群安装时的k8s-ha-install项目中，需要切换到1.20.x分支
[root@k8s-master01 ~]# cd /root/k8s-ha-install/
[root@k8s-master01 k8s-ha-install]# git checkout manual-installation-v1.20.x

# 2、创建snapshot controller
[root@k8s-master01 k8s-ha-install]# kubectl create -f snapshotter/ -n kube-system

# 3、查看snapshot controller状态
[root@k8s-master01 k8s-ha-install]# kubectl  get po -n kube-system -l app=snapshot-
controller
NAME                      READY   STATUS    RESTARTS   AGE
snapshot-controller-0     1/1     Running   0          15s

# 4、具体文档
具体文档：https://rook.io/docs/rook/v1.5/ceph-csi-snapshot.html
```

四、安装ceph客户端工具

```
# 1、安装
[root@k8s-master01 ceph]# pwd
/app/rook/cluster/examples/kubernetes/ceph
[root@k8s-master01 ceph]# kubectl  create -f toolbox.yaml -n rook-ceph
deployment.apps/rook-ceph-tools created

# 2、待容器Running后，即可执行相关命令
[root@k8s-master01 ceph]# kubectl  get po -n rook-ceph -l app=rook-ceph-tools
NAME                               READY   STATUS    RESTARTS   AGE
rook-ceph-tools-6f7467bb4d-r9vqx   1/1     Running   0          31s

# 3、执行命令ceph status
[root@k8s-master01 ceph]# kubectl -n rook-ceph exec -it deploy/rook-ceph-tools -- bash
[root@rook-ceph-tools-6f7467bb4d-r9vqx /]# ceph status
  cluster:
    id:     83c11641-ca98-4054-b2e7-422e942befe6
    health: HEALTH_OK

  services:
    mon: 1 daemons, quorum a (age 43m)
    mgr: a(active, since 13m)
    osd: 3 osds: 3 up (since 18m), 3 in (since 44m)
```

```
  data:
    pools:   1 pools, 1 pgs
    objects: 0 objects, 0 B
    usage:   3.0 GiB used, 27 GiB / 30 GiB avail
    pgs:     1 active+clean

# 4、执行命令
[root@rook-ceph-tools-6f7467bb4d-r9vqx /]# ceph osd status
ID  HOST           USED  AVAIL  WR OPS  WR DATA  RD OPS  RD DATA  STATE
 0  k8s-master03  1028M  9207M      0        0       0        0   exists,up
 1  k8s-node01    1028M  9207M      0        0       0        0   exists,up
 2  k8s-node02    1028M  9207M      0        0       0        0   exists,up

# 5、执行命令-查看状态
[root@rook-ceph-tools-6f7467bb4d-r9vqx /]# ceph df
--- RAW STORAGE ---
CLASS  SIZE    AVAIL   USED    RAW USED  %RAW USED
hdd    30 GiB  27 GiB  14 MiB   3.0 GiB      10.05
TOTAL  30 GiB  27 GiB  14 MiB   3.0 GiB      10.05

--- POOLS ---
POOL                   ID  STORED  OBJECTS  USED  %USED  MAX AVAIL
device_health_metrics   1     0 B        0   0 B      0    8.5 GiB
```

五、Ceph dashboard

5.1、暴露服务

```
# 1、默认情况下，ceph dashboard是打开的，可以通过以下命令查看ceph dashboard的service
[root@k8s-master01 ceph]# kubectl -n rook-ceph get service rook-ceph-mgr-dashboard
NAME                      TYPE        CLUSTER-IP     EXTERNAL-IP   PORT(S)    AGE
rook-ceph-mgr-dashboard   ClusterIP   10.97.5.123    <none>        8443/TCP   47m

# 可以两种方式访问：
  1.  将该service改为NodePort
  2.  通过ingress代理

# 本文档演示NodePort，ingress可以参考课程的ingress章节。
[root@k8s-master01 ceph]# kubectl -n rook-ceph edit service rook-ceph-mgr-dashboard
# 更改type类型即可
type: NodePort

# 2、访问、任意节点ip:port访问即可
[root@k8s-master01 ceph]# kubectl -n rook-ceph get service rook-ceph-mgr-dashboard
NAME                      TYPE        CLUSTER-IP     EXTERNAL-IP   PORT(S)           AGE
rook-ceph-mgr-dashboard   NodePort    10.97.5.123    <none>        8443:32202/TCP    49m
```

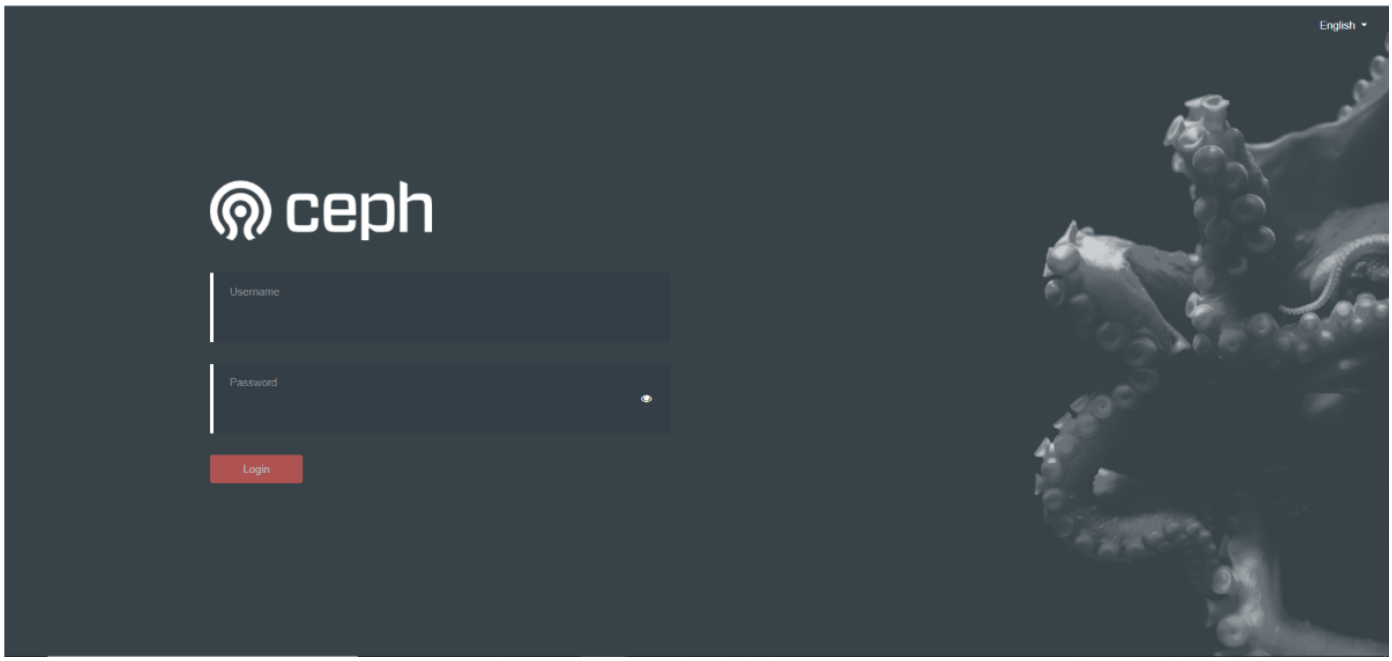


```
# 3、登录、账号为admin，查看密码
[root@k8s-master01 ~]# kubectl -n rook-ceph get secret rook-ceph-dashboard-password -o
jsonpath="{['data']['password']}" | base64 --decode && echo
@}g"P{-FVe9yb]-AV/>3
```

六、ceph块存储的使用

块存储一般用于一个Pod挂载一块存储使用，相当于一个服务器新挂了一个盘，只给一个应用使用。

6.1、创建StorageClass和ceph的存储池

```
# 1、创建文件
[root@k8s-master01 ~]# cd /app/rook/cluster/examples/kubernetes/ceph/
[root@k8s-master01 ceph]# vim storageclass.yaml
apiVersion: ceph.rook.io/v1
kind: CephBlockPool
metadata:
  name: replicapool
  namespace: rook-ceph
spec:
  failureDomain: host
  replicated:
    size: 3
---
apiVersion: storage.k8s.io/v1
kind: StorageClass
metadata:
   name: rook-ceph-block
# Change "rook-ceph" provisioner prefix to match the operator namespace if needed
provisioner: rook-ceph.rbd.csi.ceph.com
parameters:
```

```
    # clusterID is the namespace where the rook cluster is running
    clusterID: rook-ceph
    # Ceph pool into which the RBD image shall be created
    pool: replicapool

    imageFormat: "2"
    imageFeatures: layering
    csi.storage.k8s.io/provisioner-secret-name: rook-csi-rbd-provisioner
    csi.storage.k8s.io/provisioner-secret-namespace: rook-ceph
    csi.storage.k8s.io/controller-expand-secret-name: rook-csi-rbd-provisioner
    csi.storage.k8s.io/controller-expand-secret-namespace: rook-ceph
    csi.storage.k8s.io/node-stage-secret-name: rook-csi-rbd-node
    csi.storage.k8s.io/node-stage-secret-namespace: rook-ceph
    csi.storage.k8s.io/fstype: ext4

# Delete the rbd volume when a PVC is deleted
reclaimPolicy: Delete

# 2、创建块
[root@k8s-master01 ceph]# kubectl create -f storageclass.yaml
cephblockpool.ceph.rook.io/replicapool created
storageclass.storage.k8s.io/rook-ceph-block created

# 3、查看状态
[root@k8s-master01 ceph]# kubectl get CephBlockPool -n rook-ceph
NAME          AGE
replicapool   2m14s
[root@k8s-master01 ceph]# kubectl  get sc
NAME              PROVISIONER                  RECLAIMPOLICY   VOLUMEBINDINGMODE
ALLOWVOLUMEEXPANSION   AGE
rook-ceph-block   rook-ceph.rbd.csi.ceph.com   Delete          Immediate
false                  2m47s
```

此时可以在ceph dashboard查看到改Pool，如果没有显示说明没有创建成功

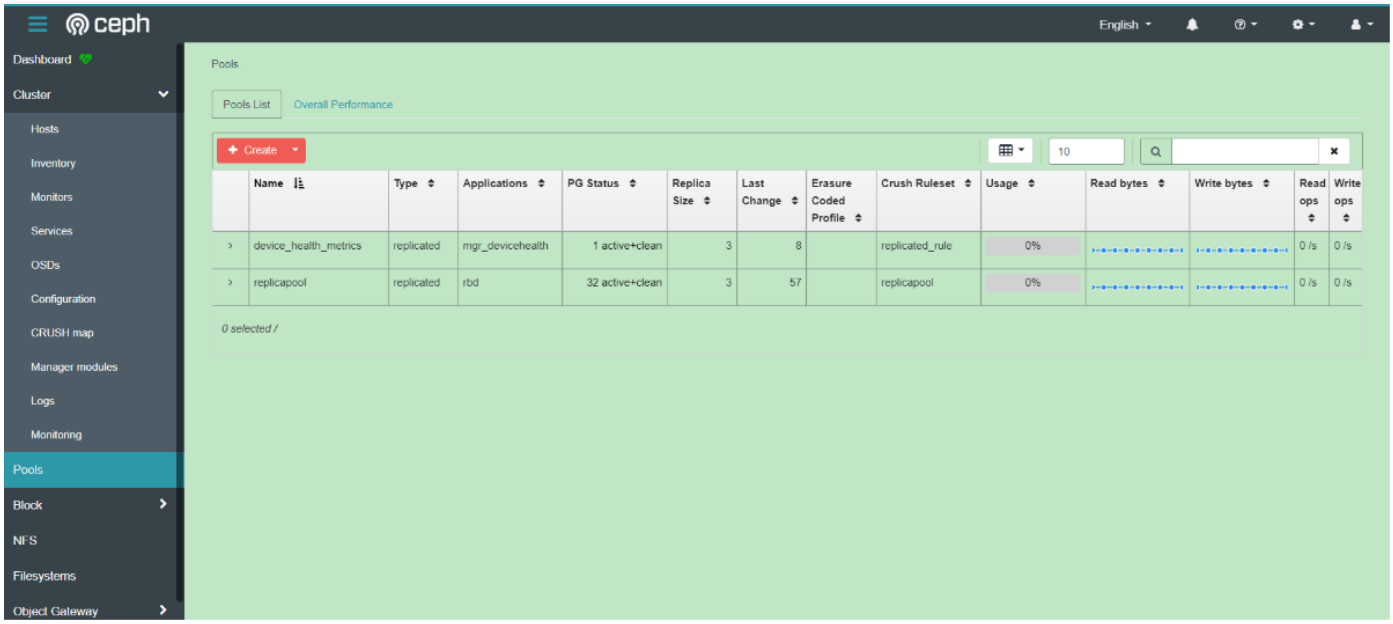

6.2、挂载测试

```
创建一个MySQL服务
[root@k8s-master01 kubernetes]# pwd
/app/rook/cluster/examples/kubernetes
[root@k8s-master01 kubernetes]# kubectl create -f mysql.yaml
[root@k8s-master01 kubernetes]# kubectl create -f wordpress.yaml

# 查看svc
[root@k8s-master01 kubernetes]# kubectl get svc wordpress
NAME        TYPE           CLUSTER-IP       EXTERNAL-IP   PORT(S)        AGE
wordpress   LoadBalancer   10.109.161.119   <pending>     80:32301/TCP   3m57s
```

该文件有一段pvc的配置

```
apiVersion: v1
kind: PersistentVolumeClaim
metadata:
  name: mysql-pv-claim
  labels:
    app: wordpress
spec:
  storageClassName: rook-ceph-block
  accessModes:
  - ReadWriteOnce
  resources:
    requests:
      storage: 20Gi
```

pvc会连接刚才创建的storageClass，然后动态创建pv，然后连接到ceph创建对应的存储

之后创建pvc只需要指定storageClassName为刚才创建的StorageClass名称即可连接到rook的ceph。如果是statefulset，只需要将volumeTemplateClaim里面的Claim名称改为StorageClass名称即可动态创建Pod，具体请听视频。

其中MySQL deployment的volumes配置挂载了该pvc：

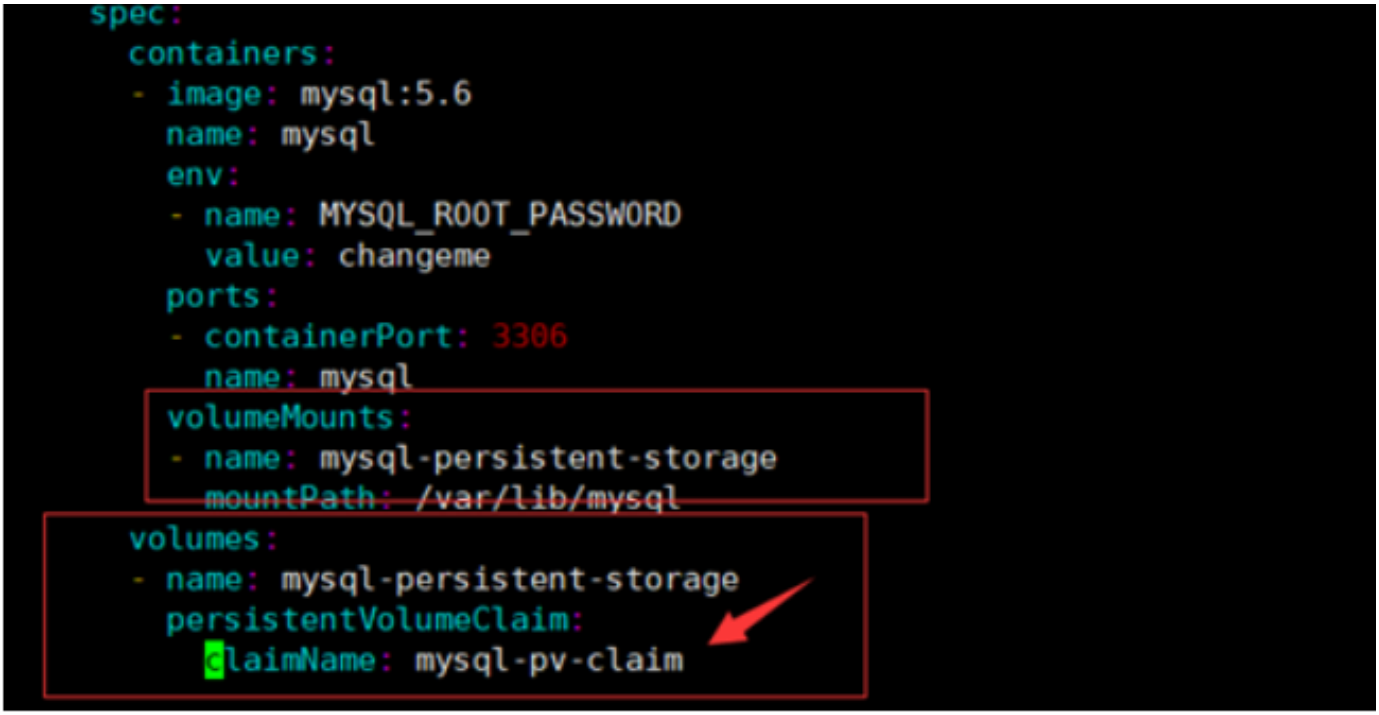

claimName为pvc的名称

因为MySQL的数据不能多个MySQL实例连接同一个存储，所以一般只能用块存储。相当于新加了一块盘给MySQL使用。

创建完成后可以查看创建的pvc和pv

```
[root@k8s-master01 kubernetes]# kubectl get pv
NAME                                       CAPACITY   ACCESS MODES   RECLAIM POLICY
STATUS   CLAIM                     STORAGECLASS      REASON   AGE
pvc-1843c13e-09cb-46c6-9dd8-5f54a834681b   20Gi       RWO            Delete
Bound    default/mysql-pv-claim    rook-ceph-block            65m
[root@k8s-master01 kubernetes]# kubectl get pvc
NAME             STATUS    VOLUME                                     CAPACITY
ACCESS MODES   STORAGECLASS      AGE
mysql-pv-claim     Bound     pvc-1843c13e-09cb-46c6-9dd8-5f54a834681b   20Gi       RWO
           rook-ceph-block   66m
```

此时在ceph dashboard上面也可以查看到对应的image

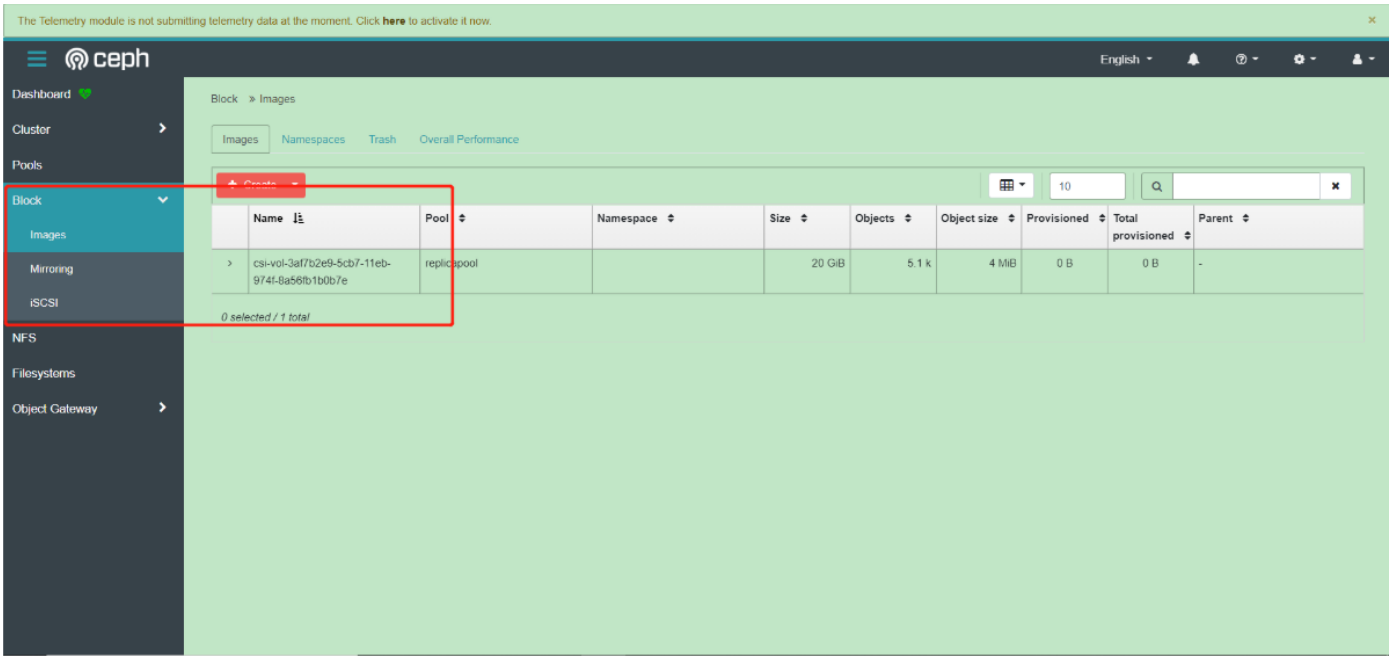

七、共享文件系统的使用

> 共享文件系统一般用于多个Pod共享一个存储

默认情况下，只能使用Rook创建一个共享文件系统。Ceph中的多文件系统支持仍被认为是实验性的，可以使用中`ROOK_ALLOW_MULTIPLE_FILESYSTEMS`定义的环境变量启用`operator.yaml`。

7.1、创建共享类型的文件系统

通过为`CephFilesystem`CRD中的元数据池，数据池和元数据服务器指定所需的设置来创建文件系统

```
[root@k8s-master01 kubernetes]# pwd
/app/rook/cluster/examples/kubernetes
[root@k8s-master01 kubernetes]# vim filesystem.yaml
apiVersion: ceph.rook.io/v1
kind: CephFilesystem
metadata:
  name: myfs
  namespace: rook-ceph
spec:
  metadataPool:    # 原数据副本数
    replicated:
      size: 3
  dataPools:       # 数据副本数
    - replicated:
        size: 3
  preserveFilesystemOnDelete: true
  metadataServer: # 原数据服务副本数
    activeCount: 1
    activeStandby: true  # 启了个从节点
```

```
# 创建
[root@k8s-master01 kubernetes]# kubectl create -f filesystem.yaml
cephfilesystem.ceph.rook.io/myfs created

# 查看，一个主，一个备
[root@k8s-master01 kubernetes]# kubectl -n rook-ceph get pod -l app=rook-ceph-mds
NAME                                    READY   STATUS    RESTARTS   AGE
rook-ceph-mds-myfs-a-5d8547c74d-vfvx2   1/1     Running   0          90s
rook-ceph-mds-myfs-b-766d84d7cb-wj7nd   1/1     Running   0          87s
```

也可以在ceph dashboard上面查看状态

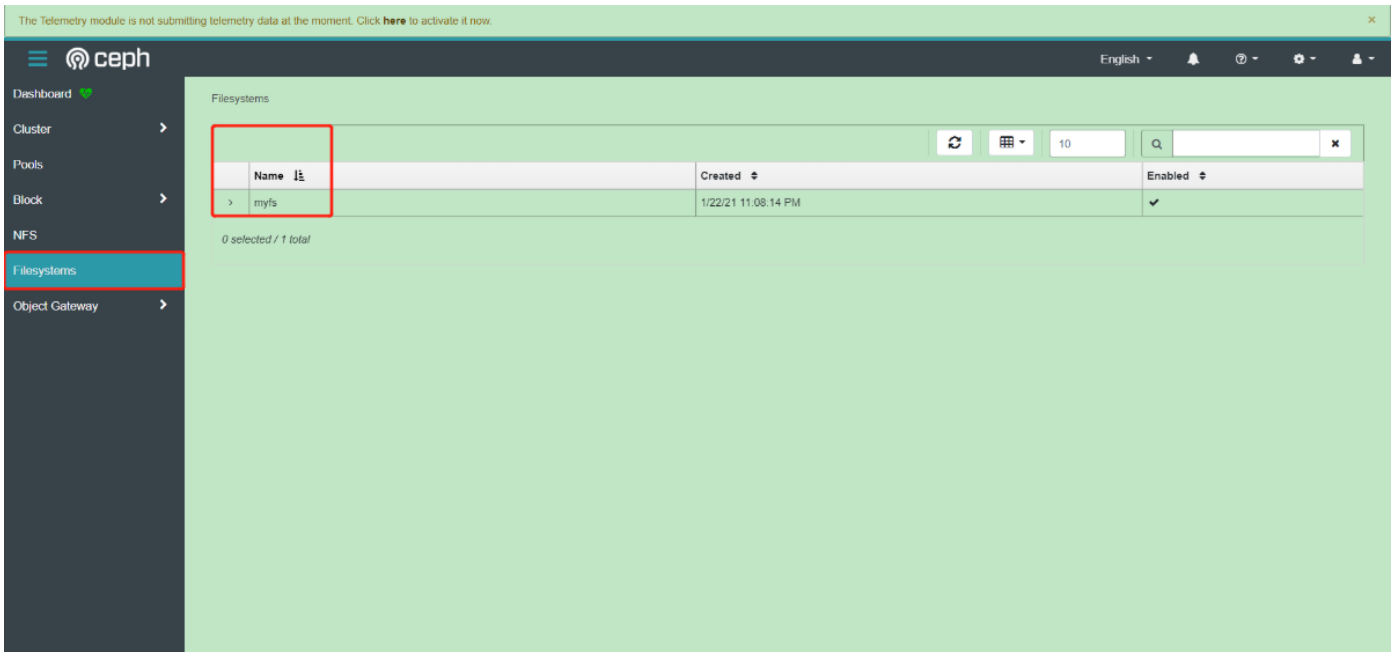

7.2、创建共享类型文件系统的StorageClass

```
官网：https://rook.io/docs/rook/v1.5/ceph-filesystem.html
apiVersion: storage.k8s.io/v1
kind: StorageClass
metadata:
  name: rook-cephfs
# Change "rook-ceph" provisioner prefix to match the operator namespace if needed
provisioner: rook-ceph.cephfs.csi.ceph.com
parameters:
  # clusterID is the namespace where operator is deployed.
  clusterID: rook-ceph

  # CephFS filesystem name into which the volume shall be created
  fsName: myfs

  # Ceph pool into which the volume shall be created
  # Required for provisionVolume: "true"
  pool: myfs-data0
```

```
  # Root path of an existing CephFS volume
  # Required for provisionVolume: "false"
  # rootPath: /absolute/path

  # The secrets contain Ceph admin credentials. These are generated automatically by
the operator
  # in the same namespace as the cluster.
  csi.storage.k8s.io/provisioner-secret-name: rook-csi-cephfs-provisioner
  csi.storage.k8s.io/provisioner-secret-namespace: rook-ceph
  csi.storage.k8s.io/controller-expand-secret-name: rook-csi-cephfs-provisioner
  csi.storage.k8s.io/controller-expand-secret-namespace: rook-ceph
  csi.storage.k8s.io/node-stage-secret-name: rook-csi-cephfs-node
  csi.storage.k8s.io/node-stage-secret-namespace: rook-ceph

reclaimPolicy: Delete
```

八、PVC扩容、快照、回滚

```
官方文档：https://rook.io/docs/rook/v1.5/ceph-csi-snapshot.html
```

8.1、快照

注意：PVC快照功能需要k8s 1.17+

ceph 创建和删除osd

1、概述

本次主要是使用ceph-deploy工具和使用ceph的相关命令实现在主机上指定磁盘创建和删除osd，本次以主机172.16.1.96(主机名hadoop96)为例，此主机系统盘为/dev/sda, 其他盘有/dev/sdb、/dev/sdc和/dev/sdd，这几个盘都是裸磁盘，目的是使用这几个盘的组合创建osd。

磁盘情况如下图：

```
[root@hadoop96 osd]# lsblk
NAME   MAJ:MIN RM  SIZE RO TYPE MOUNTPOINT
fd0      2:0    1    4K  0 disk
sda      8:0    0   20G  0 disk
├─sda1   8:1    0  300M  0 part /boot
├─sda2   8:2    0    2G  0 part [SWAP]
└─sda3   8:3    0 17.7G  0 part /
sdb      8:16   0   10G  0 disk
sdc      8:32   0   10G  0 disk
sdd      8:48   0   15G  0 disk
sr0     11:0    1 53.3M  0 rom
sr1     11:1    1  636M  0 rom
[root@hadoop96 osd]#
```

2、创建osd

使用ceph-deploy(工具安装在hadoop95上)创建osd，这里创建两个osd，其中一个数据和日志在同一个磁盘上，另外的osd日志被独立到另一个盘。

1）数据和日志在同一个磁盘上

执行ceph-deploy osd create hadoop96:/dev/sdb,然后在hadoop96上查看如下图：

```
[root@hadoop96 osd]# lsblk
NAME   MAJ:MIN RM  SIZE RO TYPE MOUNTPOINT
fd0      2:0    1    4K  0 disk
sda      8:0    0   20G  0 disk
├─sda1   8:1    0  300M  0 part /boot
├─sda2   8:2    0    2G  0 part [SWAP]
└─sda3   8:3    0 17.7G  0 part /
sdb      8:16   0   10G  0 disk
├─sdb1   8:17   0    5G  0 part /var/lib/ceph/osd/ceph-4
└─sdb2   8:18   0    5G  0 part
sdc      8:32   0   10G  0 disk
sdd      8:48   0   15G  0 disk
sr0     11:0    1 53.3M  0 rom
sr1     11:1    1  636M  0 rom
[root@hadoop96 osd]#
```

进入/var/lib/ceph/osd/ceph-4目录查看

```
[root@hadoop96 osd]# cd /var/lib/ceph/osd/ceph-4
[root@hadoop96 ceph-4]# ll
total 48
-rw-r--r-- 1 root root 490 Aug 29 22:55 activate.monmap
-rw-r--r-- 1 ceph ceph   3 Aug 29 22:55 active
-rw-r--r-- 1 ceph ceph  37 Aug 29 22:55 ceph_fsid
drwxr-xr-x 4 ceph ceph  61 Aug 29 22:55 current
-rw-r--r-- 1 ceph ceph  37 Aug 29 22:55 fsid
lrwxrwxrwx 1 ceph ceph  58 Aug 29 22:55 journal -> /dev/disk/by-partuuid/17f23e99-13dc-4a15-827b-745213c5c3dd
-rw-r--r-- 1 ceph ceph  37 Aug 29 22:55 journal_uuid
-rw------- 1 ceph ceph  56 Aug 29 22:55 keyring
-rw-r--r-- 1 ceph ceph  21 Aug 29 22:55 magic
-rw-r--r-- 1 ceph ceph   6 Aug 29 22:55 ready
-rw-r--r-- 1 ceph ceph   4 Aug 29 22:55 store_version
-rw-r--r-- 1 ceph ceph  53 Aug 29 22:55 superblock
-rw-r--r-- 1 root root   0 Aug 29 22:55 systemd
-rw-r--r-- 1 ceph ceph  10 Aug 29 22:55 type
-rw-r--r-- 1 ceph ceph   2 Aug 29 22:55 whoami
```

如上图可知日志目录被链接到/dev/disk/by-partuuid/17f23e99-13dc-4a15-827b-745213c5c3dd，我们查看/dev/disk/by-partuuid/17f23e99-13dc-4a15-827b-745213c5c3dd，如下图：

```
[root@hadoop96 ceph-4]# ll /dev/disk/by-partuuid/17f23e99-13dc-4a15-827b-745213c5c3dd
lrwxrwxrwx 1 root root 10 Aug 29 22:55 /dev/disk/by-partuuid/17f23e99-13dc-4a15-827b-745213c5c3dd -> ../../sdb2
[root@hadoop96 ceph-4]#
```

说明/dev/sdb2被作为日志的分区使用，所以新创建的osd.4默认数据和日志都在同一个磁盘/dev/sdb上不同分区。

2）osd日志被独立到另一个盘

执行ceph-deploy osd create hadoop96:/dev/sdc:/dev/sdd,然后在hadoop96上查看如下图：

```
[root@hadoop96 ~]# lsblk
NAME   MAJ:MIN RM  SIZE RO TYPE MOUNTPOINT
fd0      2:0    1    4K  0 disk
sda      8:0    0   20G  0 disk
├─sda1   8:1    0  300M  0 part /boot
├─sda2   8:2    0    2G  0 part [SWAP]
└─sda3   8:3    0 17.7G  0 part /
sdb      8:16   0   10G  0 disk
├─sdb1   8:17   0    5G  0 part /var/lib/ceph/osd/ceph-4
└─sdb2   8:18   0    5G  0 part
sdc      8:32   0   10G  0 disk
└─sdc1   8:33   0   10G  0 part /var/lib/ceph/osd/ceph-5
sdd      8:48   0   15G  0 disk
└─sdd1   8:49   0    5G  0 part
sr0     11:0    1 53.3M  0 rom
sr1     11:1    1  636M  0 rom
[root@hadoop96 ~]#
```

进入/var/lib/ceph/osd/ceph-5目录查看

```
[root@hadoop96 ~]# cd /var/lib/ceph/osd/ceph-5
[root@hadoop96 ceph-5]# ll
total 48
-rw-r--r-- 1 root root 490 Aug 29 23:22 activate.monmap
-rw-r--r-- 1 ceph ceph   3 Aug 29 23:22 active
-rw-r--r-- 1 ceph ceph  37 Aug 29 23:20 ceph_fsid
drwxr-xr-x 4 ceph ceph  61 Aug 29 23:22 current
-rw-r--r-- 1 ceph ceph  37 Aug 29 23:20 fsid
lrwxrwxrwx 1 ceph ceph  58 Aug 29 23:20 journal -> /dev/disk/by-partuuid/96eb886f-4095-4cb4-90fc-2976a8869cc1
-rw-r--r-- 1 ceph ceph  37 Aug 29 23:20 journal_uuid
-rw------- 1 ceph ceph  56 Aug 29 23:22 keyring
-rw-r--r-- 1 ceph ceph  21 Aug 29 23:20 magic
-rw-r--r-- 1 ceph ceph   6 Aug 29 23:22 ready
-rw-r--r-- 1 ceph ceph   4 Aug 29 23:20 store_version
-rw-r--r-- 1 ceph ceph  53 Aug 29 23:20 superblock
-rw-r--r-- 1 root root   0 Aug 29 23:22 systemd
-rw-r--r-- 1 ceph ceph  10 Aug 29 23:22 type
-rw-r--r-- 1 ceph ceph   2 Aug 29 23:20 whoami
[root@hadoop96 ceph-5]# /var/lib/ceph/osd/ceph-5
```

如上图可知日志目录被链接到/dev/disk/by-partuuid/96eb886f-4095-4cb4-90fc-2976a8869cc1，我们查看/dev/disk/by-partuuid/96eb886f-4095-4cb4-90fc-2976a8869cc1，如下图：

```
[root@hadoop96 ceph-5]# ll /dev/disk/by-partuuid/96eb886f-4095-4cb4-90fc-2976a8869cc1
lrwxrwxrwx 1 root root 10 Aug 29 23:22 /dev/disk/by-partuuid/96eb886f-4095-4cb4-90fc-2976a8869cc1 -> ../../sdd1
[root@hadoop96 ceph-5]#
```

说明/dev/sdd1被作为日志的分区使用，所以新创建的osd.5数据在/dev/sdc1，而日志则独立在另一个磁盘的分区/dev/sdd1。

3、删除osd

删除上面创建的osd。

1）数据和日志在同一个磁盘上的osd

将osd.4踢出集群，执行ceph osd out 4

```
[root@hadoop96 /]# ceph osd out 4
marked out osd.4.
[root@hadoop96 /]# ceph osd tree
ID WEIGHT  TYPE NAME          UP/DOWN REWEIGHT PRIMARY-AFFINITY
-6 0.03169 root hostgrp0
-2 0.03169     host hadoop96
 0 0.01700         osd.0           up  1.00000          1.00000
 4 0.00490         osd.4           up        0          1.00000
 5 0.00980         osd.5           up  1.00000          1.00000
-1 0.05099 root default
-3 0.01700     host hadoop97
 1 0.01700         osd.1           up  1.00000          1.00000
-4 0.01700     host hadoop98
 2 0.01700         osd.2           up  1.00000          1.00000
-5 0.01700     host hadoop99
 3 0.01700         osd.3           up  1.00000          1.00000
 6       0 osd.6                down        0          1.00000
[root@hadoop96 /]#
```

停止此osd进程，执行systemctl stop ceph-osd@4

```
[root@hadoop96 /]# systemctl stop ceph-osd@4
[root@hadoop96 /]# ceph osd tree
ID WEIGHT  TYPE NAME          UP/DOWN REWEIGHT PRIMARY-AFFINITY
-6 0.03169 root hostgrp0
-2 0.03169     host hadoop96
 0 0.01700         osd.0           up  1.00000          1.00000
 4 0.00490         osd.4         down        0          1.00000
 5 0.00980         osd.5           up  1.00000          1.00000
-1 0.05099 root default
-3 0.01700     host hadoop97
 1 0.01700         osd.1           up  1.00000          1.00000
-4 0.01700     host hadoop98
 2 0.01700         osd.2           up  1.00000          1.00000
-5 0.01700     host hadoop99
 3 0.01700         osd.3           up  1.00000          1.00000
 6       0 osd.6                down        0          1.00000
[root@hadoop96 /]#
```

然后执行：ceph osd crush remove osd.4,此时osd.4已经不再osd tree中了

```
[root@hadoop96 /]# ceph osd crush remove osd.4
removed item id 4 name 'osd.4' from crush map
[root@hadoop96 /]# ceph osd tree
ID WEIGHT  TYPE NAME          UP/DOWN REWEIGHT PRIMARY-AFFINITY
-6 0.02679 root hostgrp0
-2 0.02679     host hadoop96
 0 0.01700         osd.0           up  1.00000          1.00000
 5 0.00980         osd.5           up  1.00000          1.00000
-1 0.05099 root default
-3 0.01700     host hadoop97
 1 0.01700         osd.1           up  1.00000          1.00000
-4 0.01700     host hadoop98
 2 0.01700         osd.2           up  1.00000          1.00000
-5 0.01700     host hadoop99
 3 0.01700         osd.3           up  1.00000          1.00000
 4       0 osd.4                 down        0          1.00000
 6       0 osd.6                 down        0          1.00000
[root@hadoop96 /]#
```

执行ceph auth del osd.4 和 ceph osd rm 4, 此时删除成功但是原来的数据和日志目录还在，也就是数据还在

```
[root@hadoop96 ceph-4]# lsblk
NAME   MAJ:MIN RM  SIZE RO TYPE MOUNTPOINT
fd0      2:0    1    4K  0 disk
sda      8:0    0   20G  0 disk
├─sda1   8:1    0  300M  0 part /boot
├─sda2   8:2    0    2G  0 part [SWAP]
└─sda3   8:3    0 17.7G  0 part /
sdb      8:16   0   10G  0 disk
├─sdb1   8:17   0    5G  0 part /var/lib/ceph/osd/ceph-4
└─sdb2   8:18   0    5G  0 part
sdc      8:32   0   10G  0 disk
└─sdc1   8:33   0   10G  0 part /var/lib/ceph/osd/ceph-5
sdd      8:48   0   15G  0 disk
└─sdd1   8:49   0    5G  0 part
sr0     11:0    1 53.3M  0 rom
sr1     11:1    1  636M  0 rom
[root@hadoop96 ceph-4]#
```

此时我们将/dev/sdb1磁盘umount,然后将磁盘进行擦除那么数据就会被完全删除了，执行umount /dev/sdb,然后执行ceph-disk zap /dev/sdb

```
[root@hadoop96 osd]# lsblk
NAME   MAJ:MIN RM  SIZE RO TYPE MOUNTPOINT
fd0      2:0    1    4K  0 disk
sda      8:0    0   20G  0 disk
├─sda1   8:1    0  300M  0 part /boot
├─sda2   8:2    0    2G  0 part [SWAP]
└─sda3   8:3    0 17.7G  0 part /
sdb      8:16   0   10G  0 disk
sdc      8:32   0   10G  0 disk
└─sdc1   8:33   0   10G  0 part /var/lib/ceph/osd/ceph-5
sdd      8:48   0   15G  0 disk
└─sdd1   8:49   0    5G  0 part
sr0     11:0    1 53.3M  0 rom
sr1     11:1    1  636M  0 rom
[root@hadoop96 osd]#
```

这时/dev/sdb又成为裸磁盘了，也就相当于彻底删除了osd.4。

2)删除日志被独立到另一个盘的osd

执行步骤和之前类似。

将osd.5踢出集群，执行ceph osd out 5

```
[root@hadoop96 osd]# ceph osd out 5
marked out osd.5.
[root@hadoop96 osd]# ceph osd tree
ID WEIGHT  TYPE NAME          UP/DOWN REWEIGHT PRIMARY-AFFINITY
-6 0.02679 root hostgrp0
-2 0.02679     host hadoop96
 0 0.01700         osd.0           up  1.00000          1.00000
 5 0.00980         osd.5           up        0          1.00000
-1 0.05099 root default
-3 0.01700     host hadoop97
 1 0.01700         osd.1           up  1.00000          1.00000
-4 0.01700     host hadoop98
 2 0.01700         osd.2           up  1.00000          1.00000
-5 0.01700     host hadoop99
 3 0.01700         osd.3           up  1.00000          1.00000
 6       0 osd.6                 down        0          1.00000
[root@hadoop96 osd]#
```

停止此osd进程，执行systemctl stop ceph-osd@5

```
[root@hadoop96 osd]# systemctl stop ceph-osd@5
[root@hadoop96 osd]# ceph osd tree
ID WEIGHT  TYPE NAME          UP/DOWN REWEIGHT PRIMARY-AFFINITY
-6 0.02679 root hostgrp0
-2 0.02679     host hadoop96
 0 0.01700         osd.0           up  1.00000          1.00000
 5 0.00980         osd.5         down        0          1.00000
-1 0.05099 root default
-3 0.01700     host hadoop97
 1 0.01700         osd.1           up  1.00000          1.00000
-4 0.01700     host hadoop98
 2 0.01700         osd.2           up  1.00000          1.00000
-5 0.01700     host hadoop99
 3 0.01700         osd.3           up  1.00000          1.00000
 6       0 osd.6                 down        0          1.00000
[root@hadoop96 osd]#
```

然后执行：ceph osd crush remove osd.5,此时osd.5已经不再osd tree中了

```
[root@hadoop96 osd]# ceph osd crush remove osd.5
removed item id 5 name 'osd.5' from crush map
[root@hadoop96 osd]# ceph osd tree
ID WEIGHT  TYPE NAME          UP/DOWN REWEIGHT PRIMARY-AFFINITY
-6 0.01700 root hostgrp0
-2 0.01700     host hadoop96
 0 0.01700         osd.0          up  1.00000          1.00000
-1 0.05099 root default
-3 0.01700     host hadoop97
 1 0.01700         osd.1          up  1.00000          1.00000
-4 0.01700     host hadoop98
 2 0.01700         osd.2          up  1.00000          1.00000
-5 0.01700     host hadoop99
 3 0.01700         osd.3          up  1.00000          1.00000
 5       0 osd.5                down        0          1.00000
 6       0 osd.6                down        0          1.00000
[root@hadoop96 osd]#
```

执行ceph auth del osd.5和 ceph osd rm 5, 此时删除成功但是原来的数据和日志目录还在，也就是数据还在

```
[root@hadoop96 osd]# lsblk
NAME   MAJ:MIN RM  SIZE RO TYPE MOUNTPOINT
fd0      2:0    1    4K  0 disk
sda      8:0    0   20G  0 disk
├─sda1   8:1    0  300M  0 part /boot
├─sda2   8:2    0    2G  0 part [SWAP]
└─sda3   8:3    0 17.7G  0 part /
sdb      8:16   0   10G  0 disk
sdc      8:32   0   10G  0 disk
└─sdc1   8:33   0   10G  0 part /var/lib/ceph/osd/ceph-5
sdd      8:48   0   15G  0 disk
└─sdd1   8:49   0    5G  0 part
sr0     11:0    1 53.3M  0 rom
sr1     11:1    1  636M  0 rom
[root@hadoop96 osd]#
```

此时我们将/dev/sdc1磁盘umount,然后将磁盘进行擦除那么数据就会被完全删除了，执行umount /dev/sdc1,然后执行ceph-disk zap /dev/sdc

```
[root@hadoop96 osd]# lsblk
NAME   MAJ:MIN RM  SIZE RO TYPE MOUNTPOINT
fd0      2:0    1    4K  0 disk
sda      8:0    0   20G  0 disk
├─sda1   8:1    0  300M  0 part /boot
├─sda2   8:2    0    2G  0 part [SWAP]
└─sda3   8:3    0 17.7G  0 part /
sdb      8:16   0   10G  0 disk
sdc      8:32   0   10G  0 disk
sdd      8:48   0   15G  0 disk
└─sdd1   8:49   0    5G  0 part
sr0     11:0    1 53.3M  0 rom
sr1     11:1    1  636M  0 rom
[root@hadoop96 osd]#
```

这时/dev/sdc又成为裸磁盘了，也就相当于彻底删除了osd.5，但是原来作为日志的分区/dev/sdd1还在，此时如果sdd有多个分区作为其他osd的日志分区那么就不能擦除/dev/sdd盘，但是此时/dev/sdd1分区已经没有被osd使用了所以再创建osd时要记得再利用，目前我觉得只能这样。

ceph_dashboard

ph仪表板是基于Web的内置Ceph管理和监视应用程序，用于管理集群的各个方面和对象。它作为Ceph Manager守护程序的模块实现。
从Luminous开始，Ceph 提供了原生的Dashboard功能，通过Dashboard可以获取Ceph集群的各种基本状态信息，而且经过不断更新，现在已经有了各种管理功能。

一、dashboard

安装dashboard模块软件包

`dashboard`作为`mgr`的模块存在，需要安装一下模块的软件包。

包的名字叫做: `ceph-mgr-dashboard`, 使用ceph的yum源安装就可以。

```
yum install ceph-mgr-dashboard -y
```

所有`mgr`节点都需要安装，不然在启用dashboard模块的时候会报错:

```
[root@cephnode1 ~]# ceph mgr module enable dashboardError ENOENT: all mgr daemons do
not support module 'dashboard', pass --force to force enablement
```

启用dashboard

可以使用`ceph mgr module ls` 查看一下模块列表。这个列表跟安没安装`ceph-mgr-dashboard`没关系。

可以看到启用的模块里没有dashboard:

```
    "enabled_modules": [        "iostat",        "pg_autoscaler",        "restful"
],
```

执行`ceph mgr module enable dashboard`来启用dashboard。

```
[root@cephnode1 ~]# ceph mgr module enable dashboard
```

启用以后就会有监听端口了，默认是`8443`。

配置dashboard

提供证书

默认情况下，dashboard提供https访问。所以需要证书。
有三种方式：
一是使用ceph dashboard生成自签名证书。
二是指定提供的证书。
三是不使用https。

1. 生成自签名证书：

```
[root@cephnode1 ~]# ceph dashboard create-self-signed-certSelf-signed certificate created
```

1. 指定证书

```
$ ceph dashboard set-ssl-certificate -i dashboard.crt$ ceph dashboard set-ssl-certificate-key -i dashboard.key
```

1. 取消https

```
ceph config set mgr mgr/dashboard/ssl false
```

修改证书或者修改配置以后需要重启dashboard模块来生效。

```
$ ceph mgr module disable dashboard$ ceph mgr module enable dashboard
```

修改dashboard监听的端口

默认情况下，监听所有地址的`8443`或`8080`

修改监听的地址与端口：

```
$ ceph config set mgr mgr/dashboard/server_addr $IP$ ceph config set mgr mgr/dashboard/server_port $PORT$ ceph config set mgr mgr/dashboard/ssl_server_port $PORT
```

如，修改https端口为8843。

```
[root@cephnode1 ~]# ceph config set mgr mgr/dashboard/ssl_server_port 8843# 重启模块生效，可以看一下监听的端口有没有变化。[root@cephnode1 ~]# ceph mgr module disable dashboard[root@cephnode1 ~]# ceph mgr module enable dashboard
```

登录用户

为了能够登录，需要创建一个用户帐户并将其与至少一个角色相关联， dashboard提供了一组可以使用的预定义系统角色。如`administrator`表示管理员。

要创建具有管理员角色的用户，可以使用以下命令：

```
$ ceph dashboard ac-user-create <username> <password> administrator
```

如：

```
[root@cephnode1 ~]# ceph dashboard ac-user-create mydashboard abcdefg
administrator{"username": "mydashboard", "lastUpdate": 1584676335, "name": null,
"roles": ["administrator"], "password":
"$2b$12$uNxxDZgdrlCZwfQZlLwgL.L0F9aKSYznqnyfX2Lc3BBDqhZDEv9wC", "email": null}
```

现在dashboard就已经可以访问了。只是其中的`rgw`管理的功能还不可以用。
我这里按下面的步骤都做完，还有官网提到的一些其他点，最后还是不能管理`rgw`，暂时还不知道怎么回事。

为dashboard添加`rgw`的管理凭据

因为`rgw`是一个单独的组件，`dashboard`不能直接管理，需要创建凭据让`dashboard`有权限管理`rgw`。
如果不需要dashboard管理`rgw`，这一步可以跳过。

> 要使用dashboard管理rgw的功能，需要提供启用了`system`标志的用户凭据。

如果有用户，使用下面这个命令获取凭据信息。

```
radosgw-admin user info --uid=<user_id>
```

没有则需要创建。

```
$ radosgw-admin user create --uid=<user_id> --display-name=<display_name> \    --system
```

如：

```
[root@cephnode1 ~]# radosgw-admin user create --uid=dashboard --display-name=dashboard{
   "user_id": "dashboard",    "display_name": "dashboard",    "email": "",
"suspended": 0,    "max_buckets": 1000,    "subusers": [],    "keys": [        {
     "user": "dashboard",            "access_key": "MOEG3CY0LEB8JETFFA5Z",
"secret_key": "DaJBFSnyV9CgEBkRTEpYn9Tk391IppOkgybRx0wu"        }    ],
"swift_keys": [],    "caps": [],
```

记下显示的`access_key`与`secret_key`

最后，向dashboard提供凭据，以便让它可以连接`rgw`：

```
$ ceph dashboard set-rgw-api-access-key <access_key>$ ceph dashboard set-rgw-api-
secret-key <secret_key>
```

如：

```
[root@cephnode1 ~]# ceph dashboard set-rgw-api-access-key MOEG3CY0LEB8JETFFA5ZOption
RGW_API_ACCESS_KEY updated[root@cephnode1 ~]# ceph dashboard set-rgw-api-secret-key
DaJBFSnyV9CgEBkRTEpYn9Tk391IppOkgybRx0wuOption RGW_API_SECRET_KEY updated
```

登录

查看mgr中的服务

可以使用`ceph mgr services`查看mgr中提供的服务。可以确定dashboard的登录地址与端口。

```
[root@cephnode1 ~]# ceph mgr services{    "dashboard": "https://cephnode1:8843/"}
[root@cephnode1 ~]#
```

最后

打开网址登录

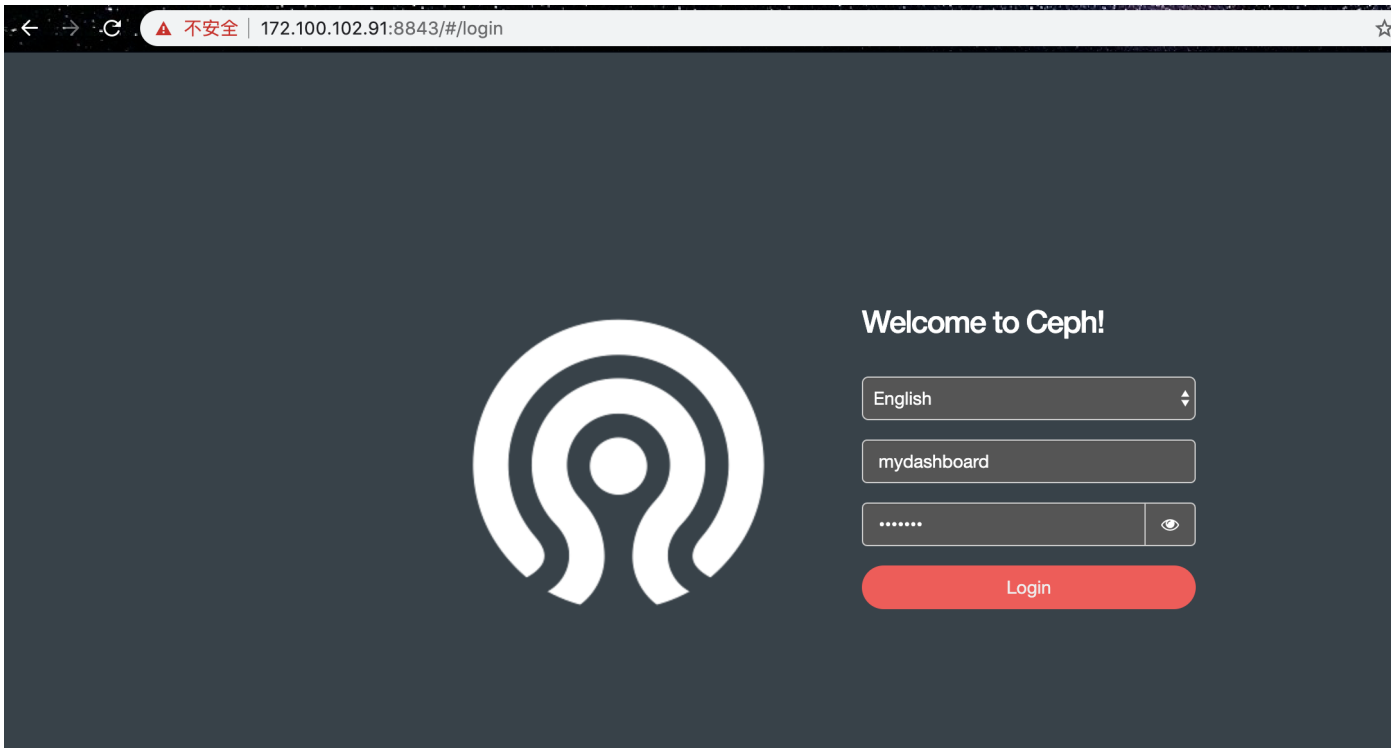

image.png

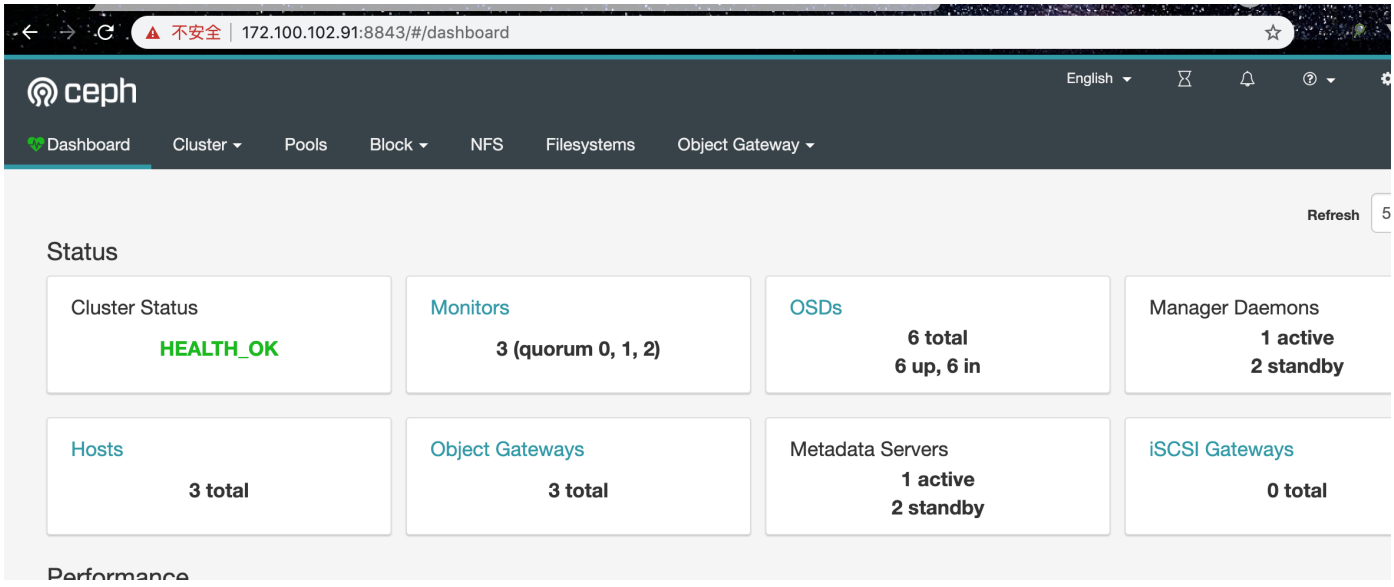

image.png

我这里能够登录，但是Object Gateway(rgw)访问还是有问题。

其他的dashhboard命令可以通过`ceph dashboard --help`查看。

二、启用Prometheus监控接口

就是暴露出去一个metrics接口，让prometheus使用。
启用prometheus模块就行。

```
[root@cephnode1 ~]# ceph mgr module enable prometheus
```

端口`9283`就可以直接访问了。

这里就是简单提一下， 至于prometheus与grafana的配置就略过了。